

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Южно-Уральский государственный университет (национальный исследовательский университет)»
Институт естественных и точных наук
Центр «ВиртУм»

Поиск и первичный анализ наборов данных по различным областям применения

02.03.02 «Фундаментальная информатика и информационные технологии»

Научный руководитель:

к.ф.-м.н., доцент центра ОП топ-
уровня в сфере ИИ «ВиртУм»

С.А. Иванов

Авторы:

студент группы ЕТ-116
Н.А. Гольдин

Челябинск, 2026 г.

Актуальность: необходимость первичного анализа

- Качество ИИ-модели напрямую зависит от качества исходных данных: пропуски, дубликаты, выбросы, шумы и ошибки разметки снижают точность результата.
- Первичный анализ позволяет заранее выявить проблемы в датасете и выбрать подходящие методы предобработки.
- Такой анализ помогает оценить пригодность набора данных до обучения модели.



Табличные данные: задача и описание данных

Задача:

Прогнозирование цены бриллианта по его физическим и качественным характеристикам.

Набор данных:

- **Название:** Diamonds Prices
- **Источник:** Kaggle, [Diamonds Prices](#)
- **Описание:** 53 940 записей о бриллиантах: масса, огранка, цвет, чистота, размеры и цена.
- **Размерность:** 53 940 записей, 10 признаков, 7 числовых и 3 категориальных



Табличные данные: атрибуты и пример


Признак	Тип	Семантика	Диапазон/категории	Пример
carat	Числовой	Масса бриллианта в каратах	0.20–5.01	0.23
cut	Категориальный	Качество огранки	Fair, Good, Very Good, Premium, Ideal	Ideal
color	Категориальный	Цвет бриллианта от D до J	D–J	E
clarity	Категориальный	Чистота бриллианта	I1, SI2, SI1, VS2, VS1, VVS2, VVS1, IF	SI2
depth	Числовой	Общая глубина, %	43–79	61.5
table	Числовой	Ширина верхней площадки, %	43–95	55
price	Числовой, целевой	Цена бриллианта в долларах США	326–18 823	326
x	Числовой	Длина камня, мм	0–10.74	3.95
y	Числовой	Ширина камня, мм	0–58.90	3.98
z	Числовой	Глубина камня, мм	0–31.80	2.43

Анализ табличных данных




Шаг 1. Качество данных

- Пропуски отсутствуют.
- Выявлено 146 дубликатов и 20 строк с нулевыми размерами x/y/z







Шаг 2. Корреляционный анализ

- Наибольшая связь с price: carat, x, y, z.
- Масса и размеры — ключевые факторы цены.



Шаг 3. Проверка выбросов

- Выбросы есть в price и carat.
- Часть значений допустима: дорогие и крупные камни встречаются реже.




Анализ табличных данных



Шаг 4. Распределения числовых атрибутов




- carat и price имеют правостороннюю асимметрию.
- Большинство бриллиантов — небольшие и недорогие.

Распределение числовых признаков датасета Diamonds Prices



Шаг 5. Распределения категор. атрибутов

- Основные признаки: cut, color, clarity.
- Чаще встречаются категории Ideal, G, SI1.



Выводы по первому разделу

- Пригодность данных: Датасет **Diamonds Prices** подходит для задачи прогнозирования цены бриллианта. Объём данных достаточный: **53 940 записи**, 7 числовых и 3 категориальных признака. Рекомендации по предварительной обработке:
- Рекомендации по предобработке:
 1. удаление дубликатов
 2. проверить или удалить строки с нулевыми размерами
 3. удаление или ограничение выбросов
 4. масштабировать числовые признаки
 5. закодировать категориальные признаки cut, color, clarity



Временные ряды: задача и описание данных

Задача:

- Тип задачи: прогнозирование будущей цены закрытия акций NVIDIA.
- Практическая значимость: прогнозирование цены акций NVIDIA может использоваться для анализа рыночной динамики, оценки трендов, поддержки инвестиционных решений и управления финансовыми рисками.

Набор данных:

- **Название, источник:** NVIDIA Daily Stock Prices Dataset.
- **Источник:** Kaggle (<https://www.kaggle.com/datasets/ibrahimshahrukh/nvidia-daily-stock-prices-20162026-dataset>).
- **Описание:** Дневные биржевые показатели акций NVIDIA за период 04.01.2016–31.12.2025. Шаг дискретизации: 1 торговый день.




Временные ряды: структура каналов многомерного временного ряда

Признак	Смысл признака	Тип данных	Пример значения
Date	Дата торгового дня	временной	2016-01-04
Open	Цена открытия торгового дня	числовой	0,787636
High	Максимальная цена за торговый день	числовой	0,794710
Low	Минимальная цена за торговый день	числовой	0,781538
Close	Цена закрытия торгового дня, целевая переменная	числовой	0,789588
Volume	Объем торгов за день, шт.	числовой	358 076 000

- Размерность: 2 514 наблюдений (торговых дней) × 5 каналов (многомерный временной ряд).
- Целевая переменная – Close.

Временные ряды: визуализация

Динамика дневных показателей акций NVIDIA



- Open, High, Low и Close изменяются синхронно. После 2023 года наблюдается выраженный рост цены акций.
- Volume имеет другой масштаб и содержит резкие всплески торговой активности.
- Пропусков и визуальных разрывов во временном ряду не обнаружено.

Анализ временных рядов




Шаг 1. Качество данных



Шаг 2. Проверка на диапазоны значений

Признак	Пропуски	Доля, %	Выбросы 3σ	Доля, %	Нижняя граница	Верхняя граница
Open	0	0,00	17	0,68	-117,665	189,766
High	0	0,00	15	0,60	-119,342	192,653
Low	0	0,00	19	0,76	-115,583	186,327
Close	0	0,00	14	0,56	-117,542	189,634
Volume	0	0,00	34	1,35	-313,5	1231,2

Диаграммы размаха для выявления потенциальных выбросов



- Пропущенных значений нет.
- Выбросы выявлены по правилу 3σ : Open — 17, High — 15, Low — 19, Close — 14, Volume — 34.
- Ценовые выбросы не удалялись, так как отражают реальные рыночные события.

Признак	Минимум	Максимум	Диапазон	Станд. отклонение
Open	0,604	208,068	207,464	51,239
High	0,623	212,178	211,555	51,999
Low	0,604	205,549	204,945	50,318
Close	0,615	207,028	206,413	51,196
Volume	65,5	3692,9	3627,4	257,4


- Ценовые каналы **Open, High, Low, Close** имеют близкий масштаб и изменяются синхронно.
- Канал **Volume** имеет другой физический смысл и значительно отличается по масштабу.
- Перед обучением модели требуется нормализация или стандартизация признаков.

Анализ временных рядов



Шаг 3. Статистический анализ

Целевая переменная Close и граница обучающей/тестовой выборки




- Для целевого признака **Close** наблюдается выраженный рост в поздней части периода.
- Среднегодовая цена закрытия демонстрирует устойчивый рост акций NVIDIA в последние годы наблюдений.



Шаг 4. Корреляционный анализ

Матрица корреляции Пирсона

	Open	High	Low	Close	Volume
Open	1.000	1.000	1.000	1.000	-0.363
High	1.000	1.000	1.000	1.000	-0.362
Low	1.000	1.000	1.000	1.000	-0.366
Close	1.000	1.000	1.000	1.000	-0.364
Volume	-0.363	-0.362	-0.366	-0.364	1.000




- Open, High, Low и Close сильно скоррелированы между собой.
- Связь **Volume** и **close** слабее, так как Volume отражает торговую активность
- , цена отражает стоимость акции
- Рекомендация: для модели можно использовать **Close**, **Volume** и производные признаки.

Анализ временных рядов



Шаг 5. Поиск и анализ шумов

- Для анализа шумовой составляющей выбран ключевой канал Close.
- Выполнена аддитивная декомпозиция ряда на тренд, сезонную компоненту и остатки.
- Тренд показывает резкий рост после **2023 года**.
- Остатки отражают случайные колебания цены и периоды повышенной волатильности.
- Данные пригодны для прогнозирования, но перед обучением модели рекомендуется использовать сглаживание, лаговые признаки и масштабирование.



Выводы по второму разделу

- **Пригодность данных:** Набор данных NVIDIA Daily Stock Prices Dataset подходит для задачи прогнозирования временного ряда. В нём представлены дневные биржевые показатели акций NVIDIA за период 2016–2025 гг.
- Выявленные проблемы и рекомендации:
 1. Ценовые каналы Open, High, Low, Close имеют близкий масштаб, а Volume сильно отличается.
 2. В данных есть нетипичные значения, особенно в объёме торгов и ценовых признаках.
 3. В поздней части периода цена резко растёт, что усложняет прогнозирование.
 4. Рекомендации: перед обучением модели необходимо масштабировать признаки, добавить лаги и скользящие средние, отдельно обработать Volume, а выбросы не удалять автоматически, так как они могут отражать реальные рыночные события.

Данные с изображениями: задача и описание данных

Задача:

- Тип задачи: многоклассовая классификация изображений животных по фотографии морды/лица.
- Практическая значимость: автоматическая сортировка изображений животных и подготовка данных для моделей компьютерного зрения.



Набор данных:

- **Название:** Animal faces dataset (AFHQv2 512x512)
- **Источник:** Kaggle ([Animal faces dataset \(AFHQv2 512×512\)](#))
- **Описание** около 15 000 изображений животных, примерно по 5 000 изображений на каждый класс. Размер: 512x512, формат:PNG.

Данные с изображениями: общая информация о датасете Cat and Dog

Параметр	Значение
Название	Animal faces dataset (AFHQv2 512x512)
Источник	Kaggle; официальное описание - репозиторий clovaai/stargan-v2
Тип данных	Изображения животных
Тип задачи	Многоклассовая классификация изображений
Классы	cat, dog, wildlife
Объем	около 15 000 изображений, примерно по 5 000 на класс
Разрешение	512 x 512 пикселей
Формат файлов	PNG для AFHQv2
Разметка	каталоговая: class = имя папки
Лицензия	Creative Commons BY-NC 4.0, некоммерческое использование с указанием источника
Чувствительные данные	персональные данные людей отсутствуют; изображения содержат животных



Данные с изображениями: примеры

Типичные изображения классов cat, dog и wildlife

cat



dog



wildlife



Структура каталогов датасета AFHQv2

```
afhq/  
├── train/  
│   ├── cat/  
│   ├── dog/  
│   └── wildlife/  
└── val/  
    ├── cat/  
    ├── dog/  
    └── wildlife/
```

Метка класса определяется по имени родительской папки.
Для задачи классификации отдельные bounding box или маски не требуются.

Анализ данных с изображениями: технические характеристики

Анализ количества и баланса классов


- В наборе представлены три класса: cat, dog, wildlife. Каждый класс содержит примерно по 5 000 изображений, поэтому сильного дисбаланса нет.

Класс	Содержание класса	Ориентировочное количество	Доля, %	Источник метки
cat	морды/лица кошек	≈ 5 000	≈ 33,3	папка cat/cats
dog	морды/лица собак	≈ 5 000	≈ 33,3	папка dog/dogs
wildlife	морды/лица диких животных	≈ 5 000	≈ 33,3	папка wildlife


Типичные изображения

- Изображения центрированы: морда/лицо животного обычно находится в центре кадра. Это упрощает обучение классификатора.

Баланс классов AFHQ: ориентировочно по описанию источника



Типичные изображения классов cat, dog и wildlife



Анализ данных с изображениями: технические характеристики

Оценка качества изображений

- Изображения имеют единый размер 512×512 пикселей и формат PNG. Объекты хорошо различимы, поэтому датасет подходит для обучения модели.

Метка класса задаётся через папку изображения. Для классификации не требуются bounding box, маски или COCO/YOLO-разметка.

- Отличие изображений: кошка выглядят более округлой (крупные глаза, острые уши), собака более вытянутой формой морды.
- Наибольшие различия между классами — прежде всего в области морды и ушей.

Оценка качества разметки


- Классы заданы явно через структуру папок, поэтому риск ошибки разметки невысокий.
- Для классов cat и dog неоднозначность минимальна. Класс wildlife является более сложным, так как объединяет разные виды диких животных.
- Перед обучением рекомендуется выборочно проверить изображения каждого класса.

Критерий	Результат оценки	Вывод
Размер изображений	512 x 512 пикселей	соответствует требованиям; объекты хорошо различимы
Формат файлов	PNG для AFHQv2	формат без сильных артефактов сжатия
Содержание кадра	морда/лицо животного расположены преимущественно в центре	подходит для классификации по визуальным признакам морды
Визуальное разнообразие	разные породы собак и кошек, разные виды диких животных	повышает обобщающую способность модели
Потенциальные ограничения	изображения в основном центрированы и похожи по композиции	при переносе на фотографии животных целиком возможна потеря качества

Папка класса	Метка класса	Ожидаемый выход модели
cat / cats	cat	вероятность принадлежности к классу кошек
dog / dogs	dog	вероятность принадлежности к классу собак
wildlife	wildlife	вероятность принадлежности к классу диких животных

Выводы по третьему разделу

- набор **AFHQv2** подходит для задачи многоклассовой классификации изображений животных.
- Выявленные особенности и рекомендации по предобработке:
 - 1) класс **wildlife** неоднороден;
 - 2) изображения в основном центрированы и похожи по композиции;
 - 3) перед обучением нужна выборочная проверка разметки.
 - 4) Рекомендации: проверить целостность файлов, выполнить нормализацию изображений, провести выборочный визуальный контроль и использовать аугментацию.



Текстовые данные: задача и описание данных

Задача:

- Тип задачи: классификация текста, анализ тональности отзывов об отелях.
- Практическая значимость: анализ отзывов помогает автоматически определять настроение клиентов, выявлять проблемы сервиса и находить сильные стороны отелей.

Набор данных:

- **Название:** Trip Advisor Hotel Reviews
- **Источник:** Kaggle ([Trip Advisor Hotel Reviews](#)).
- **Описание:** 20 491 отзыв на английском языке. Набор содержит отзывы пользователей об отелях и числовую оценку от 1 до 5.



Текстовые данные: структура и примеры

Поле	Тип	Описание	Пример значения
Review	текстовый	Исходный текст отзыва пользователя	nice hotel expensive parking...
Rating	числовой	Оценка отеля пользователем по шкале от 1 до 5	4
sentiment_label	категориальный	Увеличенная метка тональности	positive
clean_text	текстовый	Текст после очистки и удаления лишних символов	nice hotel expensive parking
lemmatized_text	текстовый	Текст после нормализации словоформ	nice hotel expensive park
no_stopwords	текстовый	Текст после удаления стоп-слов	nice hotel expensive park good deal
word_count	числовой	Количество слов после очистки	87


В наборе две основные колонки: Review и Rating.

На основе оценки можно сформировать классы: negative, neutral, positive.

Анализ текстовых данных: Анализ распределения оценок

- В наборе преобладают отзывы с оценками 4 и 5.
- Положительный класс составляет большую часть данных.
- Это создаёт дисбаланс, который нужно учитывать при обучении модели.

Показатель	Количество	Доля, %
Rating = 1	1421	6.93
Rating = 2	1793	8.75
Rating = 3	2184	10.66
Rating = 4	6039	29.47
Rating = 5	9054	44.19
negative	3214	15.68
neutral	2184	10.66
positive	15093	73.66



Анализ текстовых данных: качество текста и длина отзывов

Проверка качества текста

Пропусков и дубликатов не обнаружено.


Были найдены потенциальные URL и телефонные фрагменты, поэтому применено маскирование.

Такой шаг снижает шум и приводит тексты к единому виду перед расчетом частот и TF-IDF.

№	Исходный текст	После очистки
1	nice hotel expensive parking got good deal stay hotel anniversary, arrived la...	nice hotel expensive parking got good deal stay hotel anniversary arrived lat...
2	nice hotel good location hotel kimpton design whimsical vibe fun, staff young...	nice hotel good location hotel kimpton design whimsical vibe fun staff young ...
3	not bad location hotel short walk away space needle minute drive downtown sea...	not bad location hotel short walk away space needle minute drive downtown sea...

Анализ длины отзывов

Средняя длина отзыва около 78 слов. Есть очень длинные отзывы, поэтому распределение имеет правый хвост.



Анализ текстовых данных: лексический анализ

Предобработка текста


- Текст был очищен от лишних символов, приведён к единому виду, выполнена лемматизация и удалены стоп-слова.

После очистки	После лемматизации
nice hotel expensive parking got good deal stay hotel anniversary arrived lat...	nice hotel expensive park get good deal stay hotel anniversary arriv late eve...
nice hotel good location hotel kimpton design whimsical vibe fun staff young ...	nice hotel good location hotel kimpton design whimsical vibe fun staff young ...
not bad location hotel short walk away space needle minute drive downtown sea...	not bad location hotel short walk away space needle minute drive downtown sea...

Частотный анализ

- После удаления стоп-слов чаще всего встречаются слова, связанные с качеством сервиса: good, great, staff, location, clean.

Наиболее частотные слова после удаления стоп-слов




Анализ текстовых данных: выборки и предобработка

TF-IDF

- С помощью TF-IDF были выделены наиболее значимые слова корпуса: hotel, room, stay, good, great.


Ключевые термины по среднему TF-IDF



Информационный поиск

Поиск похожих отзывов выполнялся через косинусное сходство между TF-IDF-векторами.

Результаты информационного поиска по 3 запросам






Выводы по четвертому разделу

- Вывод: датасет **Trip Advisor Hotel Reviews** подходит для анализа тональности отзывов, так как содержит текст и готовую числовую оценку. Главная особенность набора — преобладание положительных отзывов, поэтому при построении модели важно учитывать дисбаланс классов.
- Проблемы:
 1. сильный дисбаланс классов: положительные отзывы преобладают;
 2. часть отзывов очень длинная
 3. в тексте могут встречаться служебные элементы: URL, телефоны, лишние символы.
- Рекомендации по предобработке:
 1. перед обучением нужно очистить текст, удалить стоп-слова, выполнить лемматизацию,
 2. использовать TF-IDF и учитывать дисбаланс классов через stratified split, class weights или resampling.








Основные результаты

1. подготовлено краткое описание выбранной задачи ИИ для каждого типа данных (таблицы, временные ряды, изображения, тексты);
2. подобраны и обоснован выбор наборов данных из открытых источников;
3. реализован комплекс программ на языке Python для первичного анализа;
4. сформулированы рекомендации по предобработке данных;
5. размещен исходный код в Git-репозитории: [fflaxyy/courseworker · GitHub](https://github.com/fflaxyy/courseworker)






Распределение числовых признаков датасета Diamonds Prices






Динамика дневных показателей акций NVIDIA




Признак	Пропуски	Доля, %	Выбросы 3σ	Доля, %	Нижняя граница	Верхняя граница
Open	0	0,00	17	0,68	-117,665	189,766
High	0	0,00	15	0,60	-119,342	192,653
Low	0	0,00	19	0,76	-115,583	186,327
Close	0	0,00	14	0,56	-117,542	189,634
Volume	0	0,00	34	1,35	-313,5	1231,2

Признак	Минимум	Максимум	Диапазон	Станд. отклонение
Open	0,604	208,068	207,464	51,239
High	0,623	212,178	211,555	51,999
Low	0,604	205,549	204,945	50,318
Close	0,615	207,028	206,413	51,196
Volume	65,5	3692,9	3627,4	257,4





Аддитивная декомпозиция ряда Close, период 252 торговых дня



Показатель	Значение
Пропуски в Review	0
Пропуски в Rating	0
Дубликаты по полному тексту отзыва	0
Потенциальные email	0
Потенциальные телефоны	216
Потенциальные URL	26

Термин	Среднее TF-IDF
hotel	0.071260
room	0.056258
stay	0.042383
good	0.040770
great	0.038556
staff	0.029091
location	0.027134
night	0.026239
nice	0.026020
clean	0.022987

Запрос	№	Сходство	Оценка	Класс	Фрагмент найденного отзыва
clean room friendly staff good loca...	1	0.4247	4	positive	clean room friendly service clean rooms friendly service, fresh fru...
clean room friendly staff good loca...	2	0.4020	4	positive	nice stayed 4 nights friendly staff good breakfast clean rooms free...
clean room friendly staff good loca...	3	0.3945	4	positive	friendly staff good location away cold snow went seattle, hotel dec...
dirty bathroom noise bad service	1	0.4415	2	negative	n't stay, hotel disappointing grubby dirty rooms upgraded guests ap...
dirty bathroom noise bad service	2	0.4214	1	negative	bad spa 7 days spent huge family 30+guests things stolen rooms jewe...
dirty bathroom noise bad service	3	0.3280	1	negative	place pretty bad, rooms damp dirty, water lines running walls moist...
beach pool family vacation	1	0.3342	4	positive	great family vacation great time, did n't renovated room satisfacto...
beach pool family vacation	2	0.3189	4	positive	great family vacation, esj towers great place stay, staff friendly ...
beach pool family vacation	3	0.3156	4	positive	good time family vacation plus friends, chose dominicana wanted aff...

